

中图分类号: TP751.1

学校代码: 10621

UDC 分类号: 528.8

密级: 公开

成都信息工程大学 学士学位论文

基于 U-Net 模型的卫星图像水体识别研究

Research on Water Body Identification from Satellite Images

Based on the U-Net Model

姓 名	戚智翔
学 号	2022082074
学 院	软件工程
专 业	空间信息与数字技术
研 究 方 向	图像识别及提取
指 导 教 师	魏培阳 讲师
辅助指导教师	
论文提交日期	2026 年 5 月

成都信息工程大学 学士学位论文原创性声明

本人郑重声明：所呈交的学位论文《基于联合进化算法优化的深度学习模型电量预测研究》，是本人在指导教师魏培阳指导下，进行研究工作所取得的成果。除文中已经注明引用的内容外，本学位论文的研究成果不包含任何他人创作的、已公开发表或者没有公开发表的作品的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。本学位论文原创性声明的法律 responsibility 由本人承担。

论文作者签名：年 月 日

指导教师签名：年 月 日

成都信息工程大学 学士学位论文版权使用授权书

本人完全了解成都信息工程大学关于收集、保存、使用学位论文的规定，同意如下各项内容：按照学校要求提交学位论文的印刷本和电子版本；学校有权保存学位论文的印刷本和电子版，并采用影印、缩印、扫描、数字化或其它手段保存论文；学校有权提供目录检索以及提供本学位论文全文或者部分的阅览服务；学校有权按有关规定向国家有关部门或者机构送交论文的复印件和电子版；学校可以复制、赠送和交换学位论文；学校可以公布学位论文的全部或部分内容。（保密学位论文在解密后遵守此规定）

除非另有科研合同和其他法律文书的制约，本论文的科研成果属于成都信息工程大学。

论文作者签名：年 月 日

本学位论文密级属于 级，保密期限为 年，解密后适用本授权书。

密 级		解密时间	年 月 日
学位论文 作者签名	年 月 日	指导教师 签名	年 月 日
		学校保密办公 室审核情况	年 月 日 (公章)

注：答辩通过后，最终版论文中，均须附由作者本人签名的原创声明及使用授权书。

摘要

针对卫星光学遥感水体目标提取一直以来受地物光谱异质性与水陆边界拓扑复杂的限制，且深度卷积网络主要依赖启发式人工超参数设定，难以兼顾特征泛化与极端类别不平衡等缺陷。本文构建了基于混合进化计算和增强型 U-Net 架构的全自动语义分割框架；在特征提取中以预训练的深度残差网络（ResNet-50）为骨干基座，抑制深层网络梯度衰减、加强多尺度特征抽象能力；在解码路径中采用自适应动态门控卷积块注意力机制（CBAM）显式建模跨通道的光谱依赖关系及水平、垂直正交空间上下文，实现空间与光谱权重的自适应重标定，有效加强细小河流与破碎池塘等高频边缘细节的分割保真度。在网络超参数寻优维度，基于深度耦合遗传算法（GA）、蚁群优化（ACO）、粒子群寻优（PSO）和阿尔法进化（AE）的代数算子，建立时序感知阶段性动态权重分配模型，可对每个寻优阶段的全局探索与局部开发能力产生动态调谐作用，实现学习率、批次大小、动量参数端到端自动化锁定。此外，引入了分类置信度导向的 Focal 损失与区域几何一致性约束下 Dice 损失加权联合准则并将多目标惩罚系数纳入进化寻优空间，从底层反向传播收敛逻辑上解决了水陆占比严重不平衡而造成的梯度偏置与交界处梯度失活难题。基于 Kaggle 公开水体数据集和 Sentinel-2 异构多光谱影像数据集，经过极其苛刻的实证检验，在忽略人工经验干预的情况下，得出图像像素准确率为 96.79%，F1 分数达 94.75，局部几何一致性与边界拟合高于主流网络及单一演化基准模型。本研究从数理机制上克服了深度模型训练对人工试错调参的路径依赖问题，为大尺度遥感水文动态高精度全自动解析提供了高鲁棒的计算范式。

关键词：深度学习；语义分割；混合进化算法；卫星遥感；水体识别

Abstract

The extraction of water bodies from satellite optical remote sensing is inherently constrained by spectral heterogeneity and complex water-land topological boundaries. Furthermore, existing deep convolutional networks rely heavily on heuristic manual hyperparameter configuration, struggling to balance feature generalization with extreme class imbalance. To address these deficiencies, this study constructs an autonomous semantic segmentation framework coupling hybrid evolutionary computation with an enhanced U-Net architecture. Within the feature extraction domain, a residual network (ResNet-50) serves as the backbone, while a dynamic gated convolutional block attention module (CBAM) is embedded into the decoding path. This mechanism enforces the adaptive recalibration of spatial and spectral weights, thereby fortifying the fidelity of high-frequency edge details. Within the network optimization domain, discarding the traditional empirical tuning paradigm, this research deeply integrates the Genetic Algorithm (GA), Ant Colony Optimization (ACO), Particle Swarm Optimization (PSO), and Alpha Evolution (AE) to formulate a temporal dynamic weight allocation model. This establishes the end-to-end unmanned locking of learning rates, batch sizes, and momentum parameters. Concurrently, a weighted joint criterion of Focal Loss and Dice Loss is introduced, with multi-objective penalty coefficients incorporated into the evolutionary search space, thereby eliminating gradient bias induced by spatial proportion imbalance from the underlying convergence logic. Empirical validation on heterogeneous Kaggle and Sentinel-2 datasets demonstrates that, entirely devoid of human intervention, the framework achieves a Pixel Accuracy of 96.79% and an F1-Score of 94.75, significantly outperforming conventional architectures and single-evolution baseline models. This research mechanistically dismantles the path dependence of deep model training on manual priors, establishing a highly robust computational paradigm for large-scale remote sensing hydrological parsing.

Key words: Deep learning; Semantic segmentation; Hybrid evolutionary algorithms; Satellite remote sensing; Water body identification

目 录

论文总页数：42 页

第一章 绪论	1
1.1 课题背景	1
1.2 国内外研究现状	2
1.3 本文研究内容	3
1.4 论文内容和结构	4
1.5 本章小结	4
第二章 相关理论基础概述	6
2.1 进化算法简介	6
2.1.1 遗传算法	6
2.1.2 蚁群算法	6
2.1.3 粒子群优化算法	7
2.1.4 阿尔法进化算法	8
2.2 损失函数简介	9
2.2.1 交叉熵损失（Cross-Entropy Loss）	9
2.2.2 Focal 损失（Focal Loss）	10
2.2.3 Dice 损失（Dice Loss）	10
2.3 卷积块注意力机制（CBAM）简介	11
2.3.1 通道注意力（Channel Attention）	11
2.3.2 空间注意力（Spatial Attention）	11
2.3.3 注意力模块的耦合机制	11
2.4 本章小结	12
第三章 基于混合进化协同优化的增强型 U-Net 水体识别框架	13
3.1 总体框架	13
3.2 增强型主干特征提取与动态参数调节网络	14
3.2.1 深度特征提取网络的架构选型	14
3.2.2 编码器-解码器特征级联机制	14
3.2.3 基于特征感知特征的自适应动态门控机制	15
3.3 多源进化算法动态协同与多目标联合寻优机制	16
3.3.1 多算法联合优化架构的数学定义	17
3.3.2 基于时序感知的阶段性动态权重分配策略	17

3.3.3 损失函数权重的闭环自适应协同	18
3.4 混合进化协同寻优主循环算法设计	18
3.5 损失函数融合	19
3.6 本章小结	20
第四章 实验与结果	21
4.1 实验环境与数据集介绍	21
4.1.1 实验环境配置	21
4.1.2 实验数据集来源与特征	21
4.1.3 数据预处理与样本划分	21
4.2 评价指标	22
4.3 实验结果与对比分析	24
4.3.1 基准模型确立与参数对齐	24
4.3.2 定量评价与收敛动态剖析	24
4.4 消融实验	26
4.4.1 注意力机制与多目标损失融合的消融分析	26
4.4.2 多源进化算法协同机制的有效性验证	27
4.5 本章小结	28
第五章 可视化应用	30
5.1 系统整体架构与交互逻辑设计	30
5.2 核心功能模块的工程实现	30
5.2.1 影像拖拽解析与输入校验机制	31
5.2.2 模型参数看板与动态更新调度	31
5.2 基于仿射变换的双视图同步渲染机制	32
5.3 异步推演调度与异常处理	34
5.4 本章小结	34
第六章 结论与展望	36
6.1 结论	36
6.2 展望	36
参考文献	38
致 谢	42

第一章 绪论

1.1 课题背景

高精度的地表水体提取在世界范围内的水覆盖动态监测、灾害预警和水资源管理中有着重要的作用。目前,卫星遥感影像因为其具备大范围的、高分辨率的对地观测能力,成为了人们获取地面水体分布信息最主要的途径。然而,如何从一幅幅庞杂复杂的卫星图像中快速剥离出水体语义特征是一项极其困难的物理成像任务。由于水体本身不仅会受到气象、光照或者地表覆盖类型等方面的强烈调制,还常常受到云层、高层建筑阴影等密集噪声影响,致使水陆拓扑边界非常模糊。早期的水体识别多采用物理先验法进行水体识别,例如归一化差异水体指数(NDWI)^[1]等阈值分割法^[2]或边缘检测算子^[3],当面临海量的空间分辨率、多光谱特征影像时,这些浅层次特征工程往往非常敏感局部噪声,很难兼顾到水体特征提取过程的泛化性及运算效率,方法的缺陷已经暴露无遗。

驱动该领域实现代际跨越的主要原因,是计算机视觉理论的突破。深度学习尤其是全卷积神经网络(FCN)^[4],通过对端到端自主特征进行学习,颠覆了人工特征工程的传统模式,U-Net^[5]由于具有对称的编码器-解码器结构和跳跃连接结构,可以在不同层面上实现空间细节和全局语义信息等多元化,被广泛用于遥感像素级密集分割任务^[6]中。如果再考虑一些带有深度残差映射模块的ResNet-50^[7]等网络更能提升模型对于各个尺度细微特征的捕捉速度。但是严谨的考量表明目前基于深度学习的水体识别模型遭遇了致命的自动化瓶颈:最终模型的收敛轨迹和泛化性能依赖于超参数(例如学习率、批次大小等)的人为设置。而这种模型操作往往采取启发式的人工试错方式,此类方法耗时费力且所涉及的参数非凸的空间很难找到全局最优点,使得模型在应对高度异质性的复杂遥感水体场景时,鲁棒性与自动化演进能力均受限于底层逻辑。

要彻底打破上述方法的屏障,还需引入可以摆脱人工先验干预的全局优化理论来重构深度模型训练范式。进化算法(Evolutionary Algorithms,EAs)^[8,9]是利用自然选择、交叉和变异等生物学规律来模拟种群演化过程中各类条件而获取最佳值的一类基于生物进化法则的全局启发式搜索模型。因此在极端复杂参数空间下应用遗传算法(GA)^[10]、蚁群算法(ACO)^[11,12]、粒子群优化(PSO)^[13]及阿尔法进化算法(AE)^[14]等多源策略联合寻优能够有效突破单个算法在进行全局探索与局部开发之间的博弈困境。综上所述,将增强型U-Net架构结合混合进化计算理论建立一个全自动化水体语义分割框架,不仅从底层切断了人工调参的路径依赖性,更为大规模遥感动态水文监测提供前沿的理论支撑和可实现的工程解决方案。

1.2 国内外研究现状

遥感影像中水体识别技术的早期阶段,是基于物理先验对光谱进行阈值分割和浅层特征工程的一个过程,其主要思路在于利用某种波段变换为线性或非线性结构放大水体与背景地物反射差异。在这一时期,McFeeters 提出 NDWI^[15]并利用绿光和近红外两个部分反射率之间的截差最初发现了基于指数的水体提取方法。Xu 通过引入中红外波段建立改进后归一化的差异水体指数(MNDWI)^[16],可以明显抑制建筑物阴影干扰。直至今日,此类物理阈值法依然被不断衍生,比如 Chen 等人使用准同步的 Landsat-8、Landsat-9 卫星测试八个水体指数结合 OTSU 算法自适应水体分割的能力^[17];Salim 等人将归一化差异建筑指数(NDBI)减去 NDWI,得到新型混合水体-建筑指数(WIBI)^[18]从而削弱高密度城市区域误判率。但经严谨实验证明,此类依赖物理阈值对图片质量和环境影响较小,极易受到大气气溶胶、传感器噪声以及复杂地表覆盖的干扰,当场景复杂且空间分辨率较高时,泛化难以达到预想效果,无法兼顾精度和效率。

为了突破物理阈值法底层瓶颈,基于支持向量机(SVM)^[19]、随机森林(RF)^[20,21]、K 近邻算法^[22]等分类器的传统机器学习算法被引入水体识别,实现了数据驱动范式的初步转型。rem Gümüş等人^[23]在非均匀流体动力学沿海区域进行实证研究表明,结合多光谱波段特征的 RF 与 SVM 分类器能够提供比单一指数更稳健的分割边界。但是,传统机器学习模型本质上受制于繁杂且依靠专家经验手工特征提取的方法(如纹理、形状和光谱特征堆砌)。由于无法建立从底层像素阵列到高层视觉语义的非线性映射,这些浅层模型难以跨越“语义鸿沟”,遇见破碎水体或者高频背景噪声很容易导致漏分错分问题。基于这种内生缺陷,各国开始将研究重点放在具有强大特征提取能力、端到端学习方式的深度卷积框架上。伴随着分布式算力的跃升,以 FCN 及其衍生构造(DeepLab^[24]、PSPNet^[25]、U-Net^[6])为核心的深度学习技术彻底瓦解了传统算法对人工特征工程路径的依赖。在演进网络簇中,U-Net 模型因其经典的编码器-解码器结构以及可无损融合浅层与深层特征的跳跃连接机制,在遥感密集预测任务中拥有极高的几何分割精度。

为了更好地体现深层特征,适应多尺度遥感需求,近年来国内外学者还对经典的深度卷积网络做出了大量拓展。Wang 等人^[26]提出了一种基于多维密集连接卷积神经网络的水体识别方法,通过跨层级密集特征重用,有效地提升了不同尺度水体的识别保真度。Franz 等人^[27]在对比 32 种主流的卷积神经网络(CNN)架构后发现使用具有深度残差映射能力的 ResNet50 作为编码器的 U-Net 变体,既可以有效抑制深层网络梯度衰减也能够最大程度捕获水体的全局上下文信息,并在自建河流水体分割数据集中斩获最优性能。但深度网络给予模型极高非线性

拟合能力的同时，也造成严峻的调优困境：已有的高精度水体分割模型损失曲面收敛轨迹和最终泛化能力是无限依赖于网络超参数如网络结构与学习率调度的启发式人工配置的。而在面临遥感场景中水陆像素严重失衡的普遍情况时，常规的损失函数很容易被极少的易分类背景像素所代替，导致模型在复杂水陆交界处梯度失活。这种传统手动调参方法费事耗力且无法在庞大参数空间中锁定全局最优解。这对人工先验的高度依赖是当前深度水体分割技术走向全自动、鲁棒性强的核心难题。

为了从底层逻辑上解决模型训练中的人工试错问题，开始寻找一种基于启发式全局优化方法的超参数自适应搜索框架，EAs 因其在复杂参数空间下能进行黑箱寻优而成为学者们关注的热点。EAs 将自然选择、交叉和变异等生物种群演化机制合理地重构，避免采用梯度下降法陷入最优解的可能性；Esteban^[28]等提出了一个针对图像分类的分布式演化算法，协同完善网络拓扑和超参数后精确程度得到较大飞跃。最近 Lakhan 等人^[29]面向复杂疾病检测研究并提出了一种进化深度卷积神经网络架构（EDCNNS）。研究证明了进化机制在减少计算开销并改进性能等方面具有巨大潜力。此外，Gao 等人提出的 AE^[14]，通过引入自适应步长机制、双路径演化策略实质性地加速了算法收敛和平衡全局探索。但纵观当前针对遥感水体分割任务的研究现状，可以发现绝大部分 EAs 的使用仍存在着方法论层面的断层问题：绝大多数研究仅是独立地采用一种单纯的算法，并没有从机制上解决单一算法保持种群多样性与快速收敛之间的矛盾，缺乏各种算法的对比与联合分析；同时在优化目标上往往只考虑基础超参数，而不将损失函数的动态权重配置于统一的进化寻优框架中，因此打破单一算法壁垒，构建融合多源进化策略的混合协同寻优机制，并与 U-Net 嵌套在一起，也是当下遥感语义分割领域突破“调参壁垒”和“类别失衡”限制的必然趋势。

1.3 本文研究内容

针对现有水体识别模型在超参数依赖、多尺度特征提取能力以及类别不平衡处理上的局限性，本文基于 U-Net 模型为基础，采用混合进化优化策略设计了一种全自动高精度卫星图像水体分割框架。主要研究内容如下：

建立基于混合 EAs 的全自动超参数寻优机制。集成 GA、ACO、PSO 和 AE，并设计了动态权重更新机制。在模型训练过程中，自动寻优学习率、批次大小以及动量等，完全摒弃人工调参，协同探索参数空间、精细收敛。

设计并融合自适应权重的多损失函数策略，针对遥感影像中水体面积所占比例极不均衡的情况，建立分类置信度即交叉熵损失^[30,31]或 Focal 损失（Focal Loss^[32]）与几何一致性（Dice Loss^[33]）的线性加权复合损失函数。在端到端训练

过程中动态改变权重，避免易分类样本以梯度为主导，增强模型对更繁杂的水体边界拓扑对齐能力。

优化主干网络和多尺度特征的融合，采用具有深度残差结构 ResNet50 作为编码器，在解码器阶段引入卷积块注意力机制（CBAM）^[34]、动态门控模块^[35]加强对光谱特征敏感性以及降低背景噪声。

开展基于多源遥感数据集的交叉验证与泛化性能评估。引入 Kaggle 公开水体数据集与大气校正的 Sentinel-2 多光谱影像数据集，并对掩膜进行 VOC 格式的标准化重构。通过在异构数据源上部署多组消融与对比实验，系统量化本文框架在应对多尺度水体及复杂背景噪声时的鲁棒性与边界分割精度。

1.4 论文内容和结构

本文主体划分为五个核心章节与独立的总结部分。第一章“绪论”结合水体监测的宏观地理需求，分析传统物理阈值法存在问题和目前深度网络过多依赖人工调参的内生缺陷，明确本文破局动机与核心思路；第二章“相关理论基础概述”是全文的底层数理基础，通过严密推导启发式演化策略、损失函数以及注意力机制的数学模型，为后续混合优化架构奠定基础；第三章是对全文研究方法进行阐释时所使用的主要包括“基于混合进化协同优化的增强型 U-Net 水体识别框架”。详细介绍 ResNet-50 主干以及动态门控注意力机制特征耦合的具体流程，并指出多源进化算法的时序协同关系，从而完成了对模型无人化端到端训练范式的数学定义；第四章“实验与结果”，依托 Kaggle 和 Sentinel-2 异构遥感数据集进行严苛的实证检验，建立多维度量化评估体系，论证提出框架在复杂水陆拓扑边界分割与泛化性能上的绝对优势；第五章“可视化应用”则是将算法应用至工程设计中，较为清晰透彻地介绍基于响应式框架的前端交互及双视图同步渲染引擎，真正做到从深度学习计算图到实际业务化检测界面的逻辑闭环；最后两章为结论与展望部分，汇总了整篇文献的研究发现，在充分肯定当前模型性能之外，也清楚地给出未来加入多源时序特征以实现水文动态解析的目标。

1.5 本章小结

本章从全球水资源动态监测和灾害预警的宏观需求出发，详细阐述了高精度卫星遥感水体识别的重要价值。通过对技术演进历程的分析总结，理清了传统物理阈值法面临复杂环境噪声时的泛化问题，并准确锁定当前深度学习模型所处阶段的难点在于相比于启发式人工超参数调优，其极易受制于水陆像素类别不平衡引起梯度失活，这也是使得遥感水体分割方案无法实现全自动、鲁棒性较强的障碍。

针对上述痛点,本章正式确立了以进化计算重构深度网络训练范式的研究主线。通过将 GA、ACO、PSO 与 AE 融合在一起,提出了实现多源混合协同寻优机制,从底层逻辑上彻底切断模型训练中对人工试错调参的路径依赖,并指明了未来应将自适应多损失函数结合到增强型 U-Net 架构之下更好地耦合,努力争取在端到端训练中解决高维非凸参数空间寻优和复杂拓扑边界分割两个棘手的问题。

在明确本文的研究动机和主要解题思路之后,本章详细规划了全文的逻辑体系,并给出基于多源异构遥感数据集进行交叉验证实验的实验方案。通过论述本文从宏观工程痛点到微观算法创新,为上文提供了一个清晰而完整的演进路径。接下来的第二章将会深入分析相关核心理论,详细推导神经网络架构与多重进化算法底层数学模型,以此为全自动水体分割框架落地奠定坚实的数理基础。

第二章 相关理论基础概述

2.1 进化算法简介

2.1.1 遗传算法

GA 首先由 Holland^[36]在 1975 年提出，其本质是一种基于群体演化和隐式并行计算的全局启发式随机搜索。虽然它从宏观上学习了达尔文自然选择思想、孟德尔遗传法则等，但其数理机制又将问题的解空间参数用离散或连续的“染色体”编码来表示，形成从基因型到表现型评价过程中的一套完整的评价方案。

在整个黑箱寻优过程中，算法的收敛轨迹是由三种核心的概率型算子组成：首先，选择（Selection）操作对目标函数进行适应度评估，采用轮盘赌或锦标赛等方式实现生存权重从而使得获得较好解集的搜索方向朝着更加适合目标函数运动；其次，交叉（Crossover）操作通过基因片段跨界重组的形式保证在不影响解空间拓扑多样性的同时将优良模式隐式地传递给下一代模型；最后，变异（Mutation）操作以某些具体概率阈值对局部基因位施加随机扰动来达到跳出非凸曲面的局部极值陷阱全局探索的目的。利用上述 3 种算子的马尔可夫链式迭代，GA 可以在缺乏梯度信息的复杂参数空间内自适应的趋近于全局最优解。

1) 选择操作基于个体的适应度（Fitness）进行筛选，适应度高的个体更可能被保留。常用轮盘赌选择法。选择阶段的数学模型见式(2.1)：

$$P_i = \frac{f_i}{\sum_{j=1}^N f_j} \quad (2.1)$$

其中， P_i 为个体 i 被选中的概率， f_i 为个体 i 的适应度， N 为种群规模。

2) 交叉操作通过交换两个父代个体的部分基因生成新个体。以单点交叉为例，数学模型见式(2.2)：

$$\text{Offspring Gene} = \text{Parent1 Gene}[1:k] \oplus \text{Parent2 Gene}[k+1:L] \quad (2.2)$$

其中， k 为随机交叉点， L 为基因长度， $\oplus$ 表示拼接操作。

3) 变异操作以较小概率随机改变基因位，可以被参数化为式(2.3)：

$$x_{\text{new}} = x_{\text{old}} \times (1 + \epsilon) \quad (2.3)$$

其中， ϵ 为服从高斯分布或均匀分布的随机扰动。

2.1.2 蚁群算法

ACO 是由 Dorigo 等人^[11,12]在 1996 年首次提出,它实质上就是一种基于多代理协同和分布式正反馈机制的全局启发式搜索计算方法。尽管借鉴了自然界生物群体进行自组织合作的行为,但是其数学定义中所谓“蚂蚁”被抽象为在复杂解空间中独立游走的分布式计算代理 (Agents), 而“信息素”则是严格地描述状态转移概率的全局记忆分布矩阵。

在算法的迭代寻优过程中,计算代理所需要做出怎样的路径决策一方面取决于底层物理模型的局部启发式先验信息,另一方面则是基于群体历史寻优轨迹的全局信息素浓度。通过对高质量参数解集上的信息素增量更新(即正反馈激励)以及通过引入信息素挥发机制(即全局遗忘算子)来抑制次优解的无限强化,ACO 能够有效的在超参数优化空间中摆脱局部极值陷阱,使得其能够有效地逼近全局最优解区域。

路径选择概率: 蚂蚁 k 从节点 i 转移到节点 j 的数学模型见式(2.4):

$$P_{ij}^k = \frac{[\tau_{ij}]^\alpha \cdot [\eta_{ij}]^\beta}{\sum_{l \in \text{allowed nodes}} [\tau_{il}]^\alpha \cdot [\eta_{il}]^\beta} \quad (2.4)$$

其中 τ_{ij} 为路径 (i,j) 上的信息浓度, η_{ij} 为启发因子(如路径长度的倒数), α, β 为权重参数。

信息素更新: 每轮迭代后, 信息素按公式(2.5)规则更新:

$$\tau_{ij} = (1 - \rho)\tau_{ij} + \sum_{k=1}^m \Delta\tau_{ij}^k \quad (2.5)$$

其中, ρ 为信息素挥发率, $\Delta\tau_{ij}^k$ 为蚂蚁 k 在路径 (i,j) 上释放的信息素量。

2.1.3 粒子群优化算法

PSO 由 Kennedy 和 Eberhart^[37]于 1995 年联合提出,其实质是一种基于群体智能与连续空间动量驱动的全局启发式搜索模型。超参数优化空间中每一个候选解被抽象为不具有任何质量和体积的“粒子”。整个种群在非凸高维解空间中的寻优过程并不是无秩序的随机漫步,而是受到严格的运动学状态转移方程约束的。

在迭代更新过程中,每个粒子的速度和位置演化是由两方面信息源分别决定:一种来自个体历史最优拓扑坐标的局部“认知分量”(Cognitive Component), 另一种来自全局种群历史最优拓扑坐标的“社会分量”(Social Component)。引入惯性权重可以动态调节算法收敛于全局探索与局部开发之间的边界,并耦合随机分布的学习因子,从而推进 PSO 算法能够驱动粒子群对复杂损失曲面形成具有方向指导性作用的梯度牵引力,在保障解空间拓扑多样性的同时向全局最优解区域高效、平滑地逼近。

PSO 进行搜索时每个粒子代表一个解决方案,在迭代过程中,粒子根据自身

的最优位置和全局最优位置调整飞行速度和方向。粒子的速度更新如式(2.6)所示，粒子的位置更新如式(2.7)所示。

$$v_i^{t+1} = \omega v_i^t + c_1 r_1 (p_{best,i} - x_i^t) + c_2 r_2 (g_{best} - x_i^t) \quad (2.6)$$

$$x_i^{t+1} = x_i^t + v_i^{t+1} \quad (2.7)$$

其中， d 指算法搜索空间的维度， v_{id}^k 指第 k 次迭代时粒子 i 飞行速度在第 d 维上的分量， x_{id}^k 指第 k 次迭代时粒子 i 的位置矢量在第 d 维上的分量。 p_{best} 为本粒子历史上最好的位置， g_{best} 为种群中所有粒子中当前最好的位置。 c_1 和 c_2 指加速度常数，用于调节学习的最大步长。 r_1 和 r_2 指两个随机函数，取值范围为 $[0,1]$ ，旨在增加搜索的随机性。 w 指惯性权重，为非负数，旨在调节对于解空间的搜索范围。

2.1.4 阿尔法进化算法

AE 由 Gao 与 Zhang^[14] 于 2024 年提出，是进化计算从“生物学拟合”向“代数算子驱动”转变的产物。它改变了传统算法中模糊不清的变异和交叉概念，通过建立演化矩阵（Evolution Matrix）和自适应演化路径（Evolution Path）对种群状态进行精确估计。

1) 演化矩阵的构建与群体状态采样：AE 算法的寻优起点是基于候选解空间的高阶采样。设当前种群为候选矩阵 $\mathbf{X}_{N \times D}$ ，其中 N 为种群规模， D 为超参数空间的维度。算法通过带替换的蒙特卡洛抽样生成演化矩阵 $\mathbf{E}_{N \times D}$ 。这种矩阵生成机制在数学上定义了一种对种群宏观分布的局部映射，该映射如式(2.8)、图 2-1 所示：

$$\mathbf{E}_{N \times D} = \text{Sampling}(\mathbf{X}_{N \times D}) \quad (2.8)$$

图 2-1 演化矩阵 $\mathbf{E}$ 由候选矩阵 $\mathbf{X}$ 进行抽样替换得到

在此基础上，算法通过对演化矩阵 $\mathbf{E}_{N \times D}$ 进行对角化提取与加权融合，生成表征种群进化潜力的自适应基础向量 X_{base} 。这一过程并非简单的随机选择，而是通过对种群分布密度的统计分析，确立本次迭代的最佳寻优原点。

2) 阿尔法算子 (Alpha Operator) 与步长解耦: AE 中的驱动力就是集成了高度结合了所有阿尔法算子的阿尔法算子, 它将新解的产生分解为基础向量、随机扰动项和梯度引导项三者非线性叠加如式(2.9)所示:

$$X_{new} = X_{base} + Step_{random} + Step_{adaptive} \quad (2.9)$$

其中, $Step_{random}$ 负责全局解空间的广度搜索, 其模长受控于非线性衰减因子 $\alpha(t)$, $\alpha(t)$ 的数学公式见式(2.10):

$$\alpha(t) = \exp(1 - \frac{t}{T_{max}})^\gamma \quad (2.10)$$

式中, t 为当前迭代次数, T_{max} 为最大迭代阈值。该算子确保了算法在初期具备跳出局部极值陷阱的随机性, 而在后期则实现平滑收敛。

3) 双路径演化与自适应步长适配: 为强化连续迭代步之间的时序关联, AE 算法设计了两条独立的演化路径 p_1 与 p_2 , 用于动态记录种群的累积演化方向:

$$p_1^{t+1} = (1 - c_1)p_1^t + c_1\Delta X \quad (2.11)$$

$$p_2^{t+1} = (1 - c_2)p_2^t + c_2\mathcal{G}(\Delta X) \quad (2.12)$$

式(2.11)、(2.12)中, c_1 与 c_2 分别代表不同维度的学习速率, ΔX 为当前代的演化增量, $\mathcal{G}(\cdot)$ 为梯度估计函数。

基于这两条路径生成的自适应步长 $Step_{adaptive}$, 能够实时感知解空间的曲率特征: 在平坦区域自动增大步长以加速收敛, 在剧烈波动的谷底区域则收缩步长进行精细化搜索。

2.2 损失函数简介

在遥感影像的水体语义分割中, 模型面临两个最主要问题: 一是水体和陆地背景的图像像素数量极端不平衡; 二是破碎的水体 (例如细小的河流、孤立池塘) 拓扑边界很容易在深层网络中变得平滑或丢失。为了使模型在高度非凸的损失曲面收敛到理想的泛化极值, 本节将推导一种分类置信度优化与几何一致性约束的数学模型以及建立自适应多目标复合损失函数。

2.2.1 交叉熵损失 (Cross-Entropy Loss)

标准的交叉熵损失 (Cross-Entropy Loss, CE) ^[30,31] 是通过衡量预测概率分布与真实标签 Kullback-Leibler 散度的方式来改善像素级别的分类边界。其加权形式如式(2.13)所示:

$$L_{CE} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C w_c y_{i,c} \log(p_{i,c}) \quad (2.13)$$

式中， N 为图像像素总数， C 为类别总数 $y_{i,c} \in \{0,1\}$ 为真实标签指示函数， $p_{i,c}$ 为模型输出的类后验概率， w_c 为缓解类别不平衡的静态惩罚权重。然而，在水体提取场景中，大量易分类的背景像素会产生累积效应，进而主导全局梯度更新方向，导致模型对少量的难分类水体边缘样本产生梯度失活。

2.2.2 Focal 损失（Focal Loss）

为了从数理机制上削弱易分类样本的梯度主导权，在此工作中添加 Focal Loss^[32]。损失函数利用了标准交叉熵中动态聚焦调节因子（Modulating Factor）自适应地重新分配难、易样本之间的权重的方法，如式(2.14)所示：

$$L_{Focal} = -\frac{1}{N} \sum_{i=1}^N \alpha_i (1-p_i)^\gamma \log(p_i) \quad (2.14)$$

式中， p_i 为模型对真实类别的预测置信度， α_i 为控制正负样本比例的平衡系数。聚焦参数 $\gamma > 0$ 不仅控制了权重衰减的速率，更在梯度反向传播中起到了硬挖掘（Hard Example Mining）的作用。当像素被明确分类 ($p_i \rightarrow 1$) 时，调节因子 $(1-p_i)^\gamma$ 趋近于零，从而极大抑制了该样本对总损失的贡献；反之，模型将被强制分配更多的计算资源以拟合复杂的拓扑边缘。

2.2.3 Dice 损失（Dice Loss）

无论是交叉熵损失还是 Focal loss，其本质都是基于每个像素点的微观概率评价，并没有对目标整体连通性和几何重叠度进行宏观约束。为了弥补这一缺陷，引入 Dice 相似系数（Dice Similarity Coefficient, DSC）^[33] 来确定区域级损失函数。此时的 Dice 损失在张量空间中直接测算预测掩膜与真实掩膜拓扑对齐的能力，可以展开如式(2.15)所示：

$$L_{Dice} = 1 - \frac{2 \sum_{i=1}^N p_i y_i + \epsilon}{\sum_{i=1}^N p_i + \sum_{i=1}^N y_i + \epsilon} \quad (2.15)$$

式中， p_i 与 y_i 分别代表第 i 个像素的预测概率与真实标签， ϵ 为拉普拉斯平滑项，用于规避分母为零的数值奇点并确保损失函数在训练初期的梯度稳定性。与逐像素损失不同，Dice 损失的分子项本质上计算了预测与真值的空间交集，这使得该函数对目标区域的几何形变与边界拟合极其敏感，特别适用于水文地理对象的高精度边缘分割。

2.3 卷积块注意力机制（CBAM）简介

针对卫星遥感影像中水体目标多尺度和光谱异质性，利用 CBAM^[34]进行特征增强。CBAM 是一种轻量级的即插即用模块，它包含通道注意力（Channel Attention）与空间注意力（Spatial Attention）子模块可以对特征图在通道和空间上进行实现双重标定。

2.3.1 通道注意力（Channel Attention）

通道注意力的目标在于显式地建模跨通道之间的光谱依赖关系，自适应地校准每个波段特征对所得响应的权重，强化水体相关的各类通道并减少冗余噪声。对于输入特征图 $F \in \mathbb{R}^{C \times H \times W}$ ，算法首先沿空间维度分别执行全局平均池化（Global Average Pooling, GAP）与全局最大池化（Global Max Pooling），以提取全局上下文统计量。

通道权重矢量 $M_c(F)$ 的计算公式如(2.16)所示：

$$M_c(F) = \sigma(MLP(AvgPool(F)) + MLP(MaxPool(F))) \quad (2.16)$$

式中， σ 为 Sigmoid 激活函数， MLP 代表具有共享权重的多层感知机。该机制在数理上构建了一个通道门控，使网络能够自适应增强近红外（NIR）等对水体敏感的波段权重，同时削弱由于云层、阴影干扰产生的异常光谱响应。

2.3.2 空间注意力（Spatial Attention）

空间注意力将用于强化水体区域的几何拓扑表征，以辅助模型找到复杂背景下的水陆边界。该子模块接收通道注意力校准后的特征图并沿着通道维度进行聚合，获得二维的空间特征分布。

空间权重图 $M_s(F)$ 的数学定义为式(2.17)：

$$M_s(F) = \sigma(f^{7 \times 7}([AvgPool(F); MaxPool(F)])) \quad (2.17)$$

式中， $[:, [cite_{start}]]$ 表示沿通道维度的拼接操作， $f^{7 \times 7}$ 代表感受野为 7×7 的卷积运算，用于捕获大范围的空间上下文信息。该算子生成的高亮掩膜能有效锚定细小河流及湖泊轮廓等高频空间特征，显著提升分割结果的边界保真度。

2.3.3 注意力模块的耦合机制

在实际部署时，两个子模块都是级联组合的方式。特征图可以通过通道方向重标定，再到空间方向动态增强。最终优化后的特征图 F'' 如式(2.18)所示：

$$\begin{aligned} F' &= M_c(F) \otimes F \\ F'' &= M_s(F') \otimes F' \end{aligned} \quad (2.18)$$

式中， $\otimes$ 代表元素级乘法（Element-wise Multiplication）。这种分治策略不仅维持了模型的计算效率，更通过多维特征选择机制，从底层逻辑上提升了模型在异构遥感场景下的鲁棒性。

2.4 本章小结

本章为搭建高精度卫星水体识别框架打下了坚实的数理基础。通过对 GA、ACO、PSO 和 AE 等方法进行数理模型推导，提出以全局启发式搜索代替启发式人工调参的思路，为突破深度学习超参数空间非凸寻优瓶颈提供演化计算依据；然后针对遥感场景下极端类别不平衡、边界拓扑易丢失的物理现状，论证分类置信度优化（Focal Loss）与区域一致性约束（Dice Loss）的互补机理，为进一步构造多目标自适应复合损失函数奠定扎实的逻辑基础；最后通过探究 CBAM 中光谱通道和空间维度双重标定的特征感知特征增强方式，在底层特征提取阶段达到抑制复杂地物背景噪声的效果。本章所确立的算法算子以及数学评价准则将集成于下一章提出的“混合进化协同优化的增强型 U-Net 水体识别框架”之中，从理论组件到集成系统形成完整的系统设计。

第三章 基于混合进化协同优化的增强型 U-Net 水体识别框架

本章旨在打破现有深度语义分割模型对人工启发式调参的深度依赖，正式提出一种全自动的高精度遥感水体识别框架。本框架以嵌入动态门控注意力机制的 ResNet-50-UNet 为特征提取基座，首次构建了融合多源进化计算的超参数与损失函数联合寻优机制，从底层重塑了深度网络的端到端训练范式。

3.1 总体框架

图 3-1 展示了所提出的水体识别系统整体框架，主要包含三个核心模块：(1) 超参数优化：采用进化算法优化模型超参数，通过混合策略生成最优配置；(2) 模型训练：运用编码器-解码器架构训练水体分割模型；(3) 评估：采用结合分类损失与 Dice 损失的加权损失函数进行性能评估。




图 3-1 基于混合进化算法的水体识别框架

在图像预处理阶段，模型进行了数据增强与标准化操作，所谓的标准化就是将输入的每一个像素从[0, 255]缩放到另外的一个区间，如[0, 1]等值来加速模型收敛和提高训练效率。对于数据进行增强有多种方法：随机缩放、翻转、变换颜色等。数据增强的目的主要是为了让数据更具多样性以及提升模型的泛化能力。在对图像进行预处理后，处理好的图片会被转化成 PyTorch 2.3.0 张量并发送给 GPU 上，最终得到打包好的数据传输到 U-Net 中用于训练。

在训练模型之前，有必要使用进化算法来寻找最佳的超参数组合。构建一个包含待优化超参数的搜索空间，即超参数池，这一过程是人工完成的。该池包含

对模型性能有显著影响的关键超参数，例如学习率、批次大小和优化器类型。然后选择一种或多种进化算法。在搜索过程中，算法根据预定策略持续生成新的超参数组合。对于每个新的超参数组合，进化算法会激活一个适应度评估机制。该评估通过将超参数组合应用于 U-Net 模型并在指定的验证数据集上进行训练和验证来完成。在验证数据集上，模型的性能，例如分类准确率、分割精度和收敛速度，会被量化为适应度值。更高的适应度值表明该超参数组合能使模型在当前任务中表现得更好。遵循“适者生存”的原则，进化算法会挑选出性能出色的超参数组合，直至满足终止条件，最终输出最优配置。

3.2 增强型主干特征提取与动态参数调节网络

3.2.1 深度特征提取网络的架构选型

在深度学习驱动的图像解析中，特征提取网络（Backbone）^[38]的拓扑结构决定了模型对高维语义表达上限。常规 CNN 因为连续池化操作极易导致空间几何信息的不可逆丢失、缺乏长程上下文信息融合机制等问题在面对水陆交界这类复杂遥感背景时往往敏感度不足；单一尺度的感受野提取也难以适应遥感影像中水体目标从细小沟渠到广阔湖泊的尺寸跨度。传统的深度残差网络（ResNet）虽然缓和了深层梯度耗散，但是未显式建模特征通道之间非线性依赖关系，容易忽略对水体识别至关重要的光谱特征；由于没有高效率的上采样解码机制，无法直接承担像素级的密集分割任务。经典的压缩与激励网络（SENet）^[39]仅针对全局划分通道权重进行展开优化，并没有明确地对空间几何拓扑进行考虑，在面对复杂场景时很容易出现水体边缘细节模糊和拓扑断裂的情况。

相比之下，本文搭建的增强型 U-Net 中的 ResNet-50 是预训练好的。利用深度残差映射有效抑制了层数较大的网络梯度衰减，提升模型对复杂水体纹理（如水波纹、高悬浮物浑浊区域）的判别性特征提取能力；同时充分融合 CBAM 并设计动态门控融合单元（Dynamic Gate）自适应地校准光谱和空间维度。另外由于遥感影像中常存在水陆两部分像素极度偏斜，加权多目标损失函数（交叉熵、Dice 与 Focal loss 的联合）从底层反向传播上缓解类别不平衡带来的梯度偏置，进一步提升了系统鲁棒性。

3.2.2 编码器-解码器特征级联机制

传统的 U-Net 中使用了更浅层次的卷积块，这种卷积块本身语义表征力不足以应对高分辨率复杂卫星影像。在本文中，我们将使用具有较深层级的 ResNet-50 重新构造了编码过程。在特征提取阶段，由 ResNet-50 输出的多尺度、多个梯度的特征图被无损提取，并通过跳跃连接（Skip Connection）横向传递到解码器路

径上。这样一来，非对称设计既能继承 ResNet-50 强大的特征抽象性能又利用 U-Net 的解码器拓扑实现全分辨率的像素级精确分割。

在编码阶段，ResNet-50 的核心残差瓶颈模块（Residual Block）的数学映射可抽象为式(3.1)：

$$ResidualBlock(x) = ReLU(x + Conv_3(ReLU(Conv_2(ReLU(Conv_1(x))))) \quad (3.1)$$

式中， $Conv_1, Conv_2, Conv_3$ 代表级联的卷积算子组合， x 为跨层恒等映射支路，用于无损传递前序梯度，从而加速模型收敛并提升训练稳定性。

在解码阶段，深层语义特征与编码器传递的高分辨率空间特征通过跳跃连接进行通道级联，如式(3.2)所示：

$$SkipConnection(x, y) = Concat(UpSample(x), y) \quad (3.2)$$

式中， x 为 ResNet-50 深层提取的低分辨率语义特征图， y 为编码器对应层级的浅层高分辨率特征， $UpSample$ 与 $Concat$ 分别代表上采样算子与通道维度拼接操作。级联后的复合特征张量随后输入特征融合单元进行非线性局部映射，如(3.3)所示：

$$FeatureFusion(x) = ReLU(Conv(ReLU(Conv(x)))) \quad (3.3)$$

3.2.3 基于特征感知特征的自适应动态门控机制

为了准确捕捉水体多尺度特征，本工作在增强型 CBAM 模块内部将动态门控机制嵌入到 U-Net 解码器的特征融合层中。由三个算子层构成，通过感知局部特征的拓扑复杂度进行注意力权重的空间自适应分配。

设输入特征张量为 $X \in \mathbb{R}^{B \times C \times H \times W}$ ，其动态调节过程的数理机制如下：

光谱注意力层（Spectral Attention Layer）：其目的是捕获不同通道之间的光谱依赖关系。先通过 GAP 来压缩空间维度，接着使用核个数为 5 与 3 级联一维卷积提取光谱之间的交互。大尺寸卷积核将会对全局、局部波段的分布趋势进行控制，小尺度卷积核则会对局部波段的非线性交互进行控制。如式(3.4)所示：

$$W_s = \sigma(f_3^{1D}(f_5^{1D}(GAP(X)))) \quad (3.4)$$

经此操作，模型可自适应放大 NIR 等水体敏感波段的响应权重，同步抑制阴影区域可见光波段的干扰，并有效平滑由传感器噪声引起的异常反射率波动。

空间注意力层（Spatial Attention Layer）：融合平均池化（保留整体分布）与最大池化（突出显著响应）后，算法采用空间正交解耦的 7×1 与 1×7 卷积核，分别提取水平与垂直方向的空间上下文，如式(3.5)所示：

$$W_p = \sigma(f_{1 \times 7}(f_{7 \times 1}([AvgPool(X); MaxPool(X)]))) \quad (3.5)$$

由该正交设计，水平卷积核强化了河流、运河等线状水体的拓扑连续性。垂直卷积核则凸显出湖泊等大面积水体陆地边界对比度的锐化。

动态门控混合层（Dynamic Gating Layer）：基于当前特征张量的局部复杂度，模型通过一个轻量级压缩网络（压缩比为 16: 1 的全局池化加双层卷积）自动生成空间自适应的注意力强度系数 γ 与原始特征保留系数 β ，见式(3.6)：

$$[\gamma, \beta] = \Gamma_{complexity}(X) \quad (3.6)$$

最终的自适应特征融合状态方程定义为式(3.7)：

$$X_{out} = \gamma \odot (W_p \odot X) + \beta \odot X \quad (3.7)$$

式中， $\odot$ 为元素级哈达玛积（Hadamard Product）。在水陆拓扑较复杂的交界区域，门控网络自适应增强注意力强度 γ 及减小 β ，迫使模型关注边界高频细节；而对于内部均质区域，提升 β 以尽量保存底层原始光谱特征，避免由深层卷积导致过平滑效果。残差连接的引入，进一步加强了底层梯度直通能力。

上述动态参数调整机制的过程如图 3-2 所示。




图 3-2 动态参数调整

3.3 多源进化算法动态协同与多目标联合寻优机制

单一进化算法在解决深度神经网络高维、非凸的超参数空间（如学习率，批

次大小以及多损失函数权重)时常陷入全局探索 (Exploration) 与局部开发 (Exploitation) 之间固有博弈困境。因此本文研究了基于时序感知的多源混合进化协同寻优模型 (Multi-source Hybrid Evolutionary Synergistic Optimization) 来实现对 GA 的种群多样性、ACO 的路径正反馈、PSO 的梯度牵引和 AE 的自适应矩阵抽样的代数耦合。

3.3.1 多算法联合优化架构的数学定义

设模型待优化的超参数及损失函数权重集合为高维向量空间 $\Theta = \{lr, batch_size, momentum, \lambda, \beta\}$ 。在任意迭代步 t ，四种独立进化算法 (GA, ACO, PSO, AE) 分别生成候选解并映射至 U-Net 模型，其在验证集上输出的预测评估性能 (如 F1 分数) 分别记为 $P_{GA}(t), P_{ACO}(t), P_{PSO}(t), P_{AE}(t)$ 。

本框架并不依赖单一算法的输出，而是构建了一个动态加权的联合状态更新方程，如式(3.8)所示：

$$P_{Ensemble}(t) = \omega_{GA}(t)P_{GA}(t) + \omega_{ACO}(t)P_{ACO}(t) + \omega_{PSO}(t)P_{PSO}(t) + \omega_{AE}(t)P_{AE}(t) \quad (3.8)$$

式中， $\omega_i(t)$ 为随训练迭代周期动态演变的权重系数，且在任意时刻严格满足归一化约束 $\sum \omega_i(t) = 1$ 。该联合方程的本质是构建一个多模态解空间滤波器，通过赋予不同算法在不同寻优阶段的主导权，实现解空间探索轨迹的平滑接力。

3.3.2 基于时序感知的阶段性动态权重分配策略

为最大化协同效能，本研究将整个网络训练周期 T_{max} 划分为三个具有明确数理目标的寻优阶段，并设计了非线性的阶段性权重分配函数

$\mathbf{W}(t) = [\omega_{GA}(t), \omega_{ACO}(t), \omega_{PSO}(t), \omega_{AE}(t)]^T$ 。设相对迭代进度 $r = t / T_{max}$ 其动态切换逻辑定义如下：

早期拓扑探索阶段 ($0 \leq r < \tau_1$)：

此阶段的核心目标是最大化种群在超参数空间中的拓扑覆盖面，防止模型陷入局部极小值。因此，算法赋予具备强随机变异能力的 GA 最高权重如式(3.9)所示：

$$\omega_{GA}(t) = 0.35 + \delta_1(t), \quad \delta_1(t) \sim \mathcal{U}(-0.05, 0.05) \quad (3.9)$$

其余权重在剩余空间内均匀分配。引入微小均匀分布扰动 $\delta_1(t)$ 用于打破确定性搜索的对称性壁垒，强化全局拓扑搜索鲁棒性。

中期双驱动收敛阶段 ($\tau_1 \leq r < \tau_2$)：

随着可行解区域的初步圈定，算法需要快速向潜在的高优区域靠拢。此阶段动态抑制 GA 权重，转而激活基于信息素累积的 ACO 与基于动量梯度的 PSO，如式(3.10)所示：

$$\omega_{ACO}(t) = 0.28, \quad \omega_{PSO}(t) = 0.32 \quad (3.10)$$

这一参数组合在数学上是一个“路径-梯度”双驱动演化场（Path-Gradient Dual Drive）。ACO 将路径置信度固定在离散的高维空间，而 PSO 通过连续空间的梯度牵引力加快收敛速度进行粗粒度向细粒度搜索。

后期精英解压缩阶段 ($\tau_2 \leq r \leq 1$)：

在收敛末期，为突破精度瓶颈并消除残余的参数震荡，模型将优化主导权移交至具备先进步长解耦机制的 AE，如式(3.11)所示：

$$\omega_{AE}(t) = 0.40 + \delta_2(t), \quad \delta_2(t) \sim \mathcal{U}(-0.06, 0.06) \quad (3.11)$$

依托 AE 算子的自适应基础向量与双路径演化记忆，模型对当前最优参数集附近的非凸邻域进行极端精细的拓扑压缩与微调，最终锁定具有最强泛化能力的全局最优超参数组合 Θ^* 。

3.3.3 损失函数权重的闭环自适应协同

在传统的语义分割网络中，分类置信度与几何一致性损失的权重（即式中的 λ 与 β ）通常作为静态常量注入模型，难以适应训练不同阶段对梯度分布的需求差异。在本研究构建的混合进化框架中， λ 与 β 被直接编码进候选解向量

$X \in \mathbf{X}_{N \times D}$ 。

通过上述动态加权联合寻优机制，模型在早期倾向于以更高的交叉熵/Focal 分类损失（ λ ）来快速建立像素级别的判别边界；进化算法在收敛末期根据评估反馈自适应地增加 Dice 损失权重（ β ），对水体宏观拓扑和复杂边缘施予严酷的几何惩罚。彻底实现了超参数寻优和多目标损失调控在端到端训练中的逻辑闭环。

3.4 混合进化协同寻优主循环算法设计

本节将 3.2 节中建立的多源进化动态协同数理模型转化为具体的计算拓扑与算法控制流。算法的核心在于通过相对训练进度 r 触发硬边界切换，并在每一代（Generation）中利用动态权重 $\mathbf{W}(t)$ 决定各进化算子（GA, ACO, PSO, AE）生成候选解的子种群比例或演化强度。整个超参数与损失函数权重的端到端寻优过程如算法 1 所示。

算法 1: 基于多源混合进化协同的 U-Net 超参数与损失权重寻优

输入(Input):

U-Net 特征架构, 训练/验证集, 最大迭代 T_{max} , 种群规模 N

搜索空间 $\Omega = [lr, batch_size, momentum, \lambda, \beta]$, 阈值 $\tau_1 = 0.3, \tau_2 = 0.7$

输出(Output): 全局最优超参数与损失权重组合 Θ^*

算法流程(Algorithm Control Flow):

1. Initialize: 采用高斯分布初始化种群 $X(0) \in \Omega$
 2. Evaluate: 计算初始验证集 F1 分数 $f(X)$, 并设 $\Theta^* \leftarrow \arg \max f(X)$
 3. For $t = 1$ to T_{max} do:
 4. $r \leftarrow t / T_{max}$ /*计算寻优相对进度*/
 5. If $r < \tau_1$: $W(t) \leftarrow [0.35 + \delta_1, w_{res}, w_{res}, w_{res}]$, $\delta_1 \sim U(-0.05, 0.05)$
 6. Else If $\tau_1 \leq r < \tau_2$: $W(t) \leftarrow [w_{res}, 0.28, 0.32, w_{res}]$
 7. Else: $W(t) \leftarrow [w_{res}, w_{res}, w_{res}, 0.40 + \delta_2]$, $\delta_2 \sim U(-0.06, 0.06)$
 8. 归一化 $W(t)$ 使和为 1, 并据此将 $X(t)$ 划分为四个并行子集
 9. Execute Parallel Operators:
 10. $X_{GA} \leftarrow GA$ (选择交叉变异)
 11. $X_{ACO} \leftarrow ACO$ (信息素挥发, 路径概率转移)
 12. $X_{PSO} \leftarrow PSO$ (动量更新, 极值牵引)
 13. $X_{AE} \leftarrow AE$ (双路径矩阵抽样与自适应步长扰动)
 14. Merge & Evaluate: $X_{new}(t) \leftarrow X_{GA} \cup X_{ACO} \cup X_{PSO} \cup X_{AE}$, 计算 $f(X_{new})$
 15. Update: 基于锦标赛/贪婪策略更新子代 $X(t+1)$
 16. If $\max f(X(t+1)) > f(\Theta^*)$ then $\Theta^* \leftarrow \arg \max f(X(t+1))$
 17. End For
 18. Return Θ^*
-

3.5 损失函数融合

为了同步优化模型的分类置信度与几何一致性, 提出线性加权损失融合策略。该策略将像素级分类损失 (可实例化为交叉熵损失 L_{CE} 或 Focal 损失 L_{Focal}) 与区域级 Dice 损失 (L_{Dice}) 相结合获得如(3.12)所示的复合损失函数:

$$L_{Total} = \lambda \times L_{cls} + \beta \times L_{Dice} \quad (3.12)$$

式中, L_{cls} 为分类损失算子; L_{Dice} 为 Dice 损失项。 λ 、 β 两个系数是动态权重的, 默认初始值都为 1, 在训练模型时, 这些系数并不会稳定维持一段时间, 而是通过混合进化算法 (如 GA 或 PSO) 来自适应调节其权重大小从而在不同收

敛阶段动态平衡各损失组件对优化的贡献度。通过端到端地联合训练模型能够使反向传播能同时达到以下两方面目标：

分类置信度的优化：通过约束模型输出概率和真实标签之间的距离来提高像素级别的判别精准性。

几何一致性的改进：增强预测区域与真实掩膜之间的拓扑对齐度，以更精细地分割地物边界。

3.6 本章小结

本章详细介绍了基于高精度卫星水体识别的混合进化优化 U-Net 框架的整个构建过程。首先，针对遥感影像解析中的自动化难题提出由超参数全局寻优、深度网络特征提取和多目标几何评价三个阶段组成的总体思路。然后在主干网络上摒弃浅层编码器，采用 ResNet-50 残差结构作为基座；并在解码路径中创新性地引入一种门控注意力机制来感知局部特征的拓扑复杂程度，最终实现光谱敏感度与空间边界保真度之间的权重自适应重标定。

为从底层逻辑上突破人工调参的局限性，本章对多源进化算法联合寻优机制做了详细推导。通过将 GA 的多样性探索、ACO 的路径正反馈、PSO 的梯度牵引与 AE 的自适应步长抽样相耦合建立四阶段动态权重分配模型，实现对学习率、批次大小及动量参数的端到端自动化锁定。同时针对水陆像素类别极端不平衡的物理现状确定 Focal loss 和 Dice loss 线性加权复合评价准则，并把该多目标损失的权重系数纳入进化寻优空间彻底完成分类置信度、几何一致性闭环优化。本章所建构的理论架构及数学模型是第四章基于真实遥感数据集的模型实证及性能评估研究的计算拓扑和方法论依据。

第四章 实验与结果

本章旨在通过大规模实证研究验证基于混合进化算法优化的 U-Net 框架在遥感水体提取任务中的有效性。首先介绍实验运行的硬件环境与数据集构成，随后确立多维度的性能评价体系。通过与多种主流基准模型的定量对比及消融实验分析，从收敛性、稳健性及边缘保真度等维度对本文提出的混合进化优化策略进行全面论证。

4.1 实验环境与数据集介绍

4.1.1 实验环境配置

为保障深度神经网络训练的高效性与混合进化算法在大规模搜索空间中的实时反馈能力，本研究构建了基于高性能计算单元的实验平台。模型开发与算法实现均基于 PyTorch 2.3.0 深度学习框架。具体的软硬件参数配置如表 4-1 所示。

表 4-1 实验环境软硬件配置表

配置项目	参数详情
操作系统	Windows 11 Pro
中央处理器（CPU）	Intel(R) Ultra 7 270K Plus
图形处理器（GPU）	NVIDIA GeForce RTX 5070 (12GB VRAM)
深度学习框架	PyTorch 2.3.0 / torchvision 0.18.0
加速库	CUDA 12.1 / cuDNN 8.9.2
开发语言	Python 3.10

4.1.2 实验数据集来源与特征

本研究采用双源数据集融合方案，以提升模型在异构地理环境下的泛化能力：
Kaggle 公开水体数据集：该数据集由 Francisco Escobar 于 Kaggle 发布，包含大量经预处理的卫星观测样本。其原始掩膜（Mask）基于 NDWI 计算生成的二值图，其中白色像素（值为 1）表征水体，黑色像素（值为 0）表征非水体背景。该数据集提供了丰富的各种地貌背景下的水体形态，为模型初期特征权重的建立提供了坚实基础。

Sentinel-2 多光谱遥感影像数据集：该数据集是 2021 年 Luo 等人^[40]提供的经过大气校正的 Sentinel-2 卫星上获得的多光谱遥感影像。高空间分辨率 10 米的 Sentinel-2 拥有强大的多光谱探测能力，可以较为精确地捕捉细小的地学拓扑特

征, 本文对重点区域采用人工目视解译和 Google Earth 高分辨率影像交叉验证的方式进行了区域化标注, 保障了地表真值 (Ground Truth) 的高保真度。

4.1.3 数据预处理与样本划分

为使输入张量符合增强型 U-Net 架构的要求, 同时保证训练数值稳定, 本研究进行以下预处理:

几何重构与归一化: 把所有异构来源的影像都从图片剪切成 512×512 像素的瓦片 (Patches)。为了加快梯度收敛, 以及减少量纲干扰, 将原始像素值由 $[0, 255]$ 归一化到 $[0, 1]$ 间, 其中 0 是背景, 1 是目标。

格式转化与掩膜重构: 对 Sentinel-2 影像进行自动化的转换脚本, 将其转换为标准 VOC 语义分割格式以确保模型对于目标类别 (水体) 和背景类别的映射。

自适应数据增强: 为了减小在遥感场景中过拟合的情况, 提出了随机多尺度缩放、水平/垂直翻转和颜色空间抖动等方法来加以调整。这种操作可以有效地提高模型抗干扰传感器噪声以及光照角度变化的能力。

样本集划分: 本实验采用随机抽样的方式, 将融合好的数据按照 70% 训练集、15% 验证集和 15% 测试集来划分。其中验证集作为进化算法的适应度反馈 (F1 分数), 而测试集则是最终性能指标的衡量标准。

4.2 评价指标

为了多维度、系统性地评价基于混合进化算法优化的 U-Net 框架在遥感水体识别任务中的整体能力, 本文从像素准确率、F1 分数、平均交并比、平均像素准确率和平均精确率等五个方面来量化该模型综合表现。这些指标也是从全局分类效果好坏、局部几何一致性以及对类别不平衡处理等方面对模型进行严格考察。

像素准确率 (PA)

像素准确率反映了模型在像素级区分水体与背景总能力的直观水平, 即预测正确的像素数占总像素数的比例。其数学表达式定义如式(4.1)所示:

$$PA = \frac{TP + TN}{TP + TN + FP + FN} \quad (4.1)$$

式中, TP 、 TN 、 FP 和 FN 分别代表真阳性、真阴性、假阳性与假阴性像素数。PA 的取值范围为 $[0, 1]$, 越接近 1 表明模型对全图像素类别的整体判定越准确。然而, 在背景像素占据绝对主导的遥感场景下, PA 往往无法敏感捕获少数类水体样本的识别精度。

F1 分数 (F1_Score)

由于遥感影像中水体面积占比通常远小于陆地背景, 模型极易产生向多数类

偏斜的倾向。F1 分数作为精确率（Precision）与召回率（Recall）的谐波平均值，是评估不平衡数据集分割性能的核心指标，其计算公式如式(4.2)、(4.3)所示：

$$Precision = \frac{TP}{TP + FP}, \quad Recall = \frac{TP}{TP + FN} \quad (4.2)$$

$$F1_Score = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (4.3)$$

F1 分数越高，意味着模型在有效减少水体漏检（提高 Recall）的同时，误报水平较低（提高 Precision），保持了分类置信度与泛化性之间的协调。

平均交并比（mIoU）

平均交并比的目标是定量刻画模型预测区域与真实掩膜之间空间重叠程度及其几何拓扑一致性。对于包含 C 个类别的语义分割任务（本研究中 $C = 2$ ，即水体与背景），mIoU 的定义如式(4.4)所示：

$$mIoU = \frac{1}{C} \sum_{c=1}^C \frac{TP_c}{TP_c + FP_c + FN_c} \quad (4.4)$$

较高的 mIoU 值意味着预测出的水体轮廓与 Ground Truth 的边界拟合度更高，这对于刻画细长河流或破碎池塘等复杂水文几何形态具有重要评价价值。

平均像素准确率（mPA）

平均像素准确率独立计算每一类别的分类精度并求取平均值，旨在衡量模型对不同地学类别特征的学习均衡性，其计算公式如(4.5)所示。

$$mPA = \frac{1}{C} \sum_{c=1}^C \frac{TP_c}{TP_c + FN_c} \quad (4.5)$$

这个指标不仅体现了模型对局部细节识别的鲁棒性，更体现出它克服背景噪声和复杂地物干扰的能力。

平均精确率（mPrecision）

平均精确率用于评估模型正向预测结果的可靠性，反映了所有判定为水体的像素中真实属于水体像素的比例，其定义如(4.6)所示。

$$mPrecision = \frac{1}{C} \sum_{c=1}^C \frac{TP_c}{TP_c + FP_c} \quad (4.6)$$

较高的 mPrecision 意味着模型有更强的抑制误报（假阳性）能力，减少由于云影或建筑物投影以及陆地低反射区域引起的误识别风险。

综上，PA 与 F1 分数主要验证模型的全局判别效能；mIoU 侧重于评估边界的几何精度；mPA 强化了对局部特征识别鲁棒性的考核；而 mPrecision 则对假阳性误报率进行了严苛约束。这些指标的有机耦合，构建了对改进的 U-Net 模型综合性能的严密评价闭环。

4.3 实验结果与对比分析

为客观、量化地评估基于混合进化算法优化的 U-Net 框架在复杂遥感水体提取任务中的先进性，本节设计了严格的基准对比实验。实验不仅横向对比了不同 Backbone 的表征能力，还纵向验证了不同自适应优化器（Optimizer）对非凸损失曲面寻优轨迹的影响。

4.3.1 基准模型确立与参数对齐

本实验选用了三种经典的主干网络作为比较对象，其中主要包括 VGG-16（基于线性堆叠的深层网络）、DenseNet(密集特征复用的网络)以及 MobileNet（深度可分离卷积的轻量化网络）。同时，考虑到梯度更新策略不同，也引入了两种优化器，一个是随机梯度下降（SGD）；另一个则采用自适应矩估计（Adam）。

为确保横向对比的绝对公平性，所有基准模型均被统一部署于 U-Net 的编码器-解码器拓扑架构中，并共享完全相同的初始超参数设定：最大初始学习率统一锁定为 1×10^{-4} ，最小学习率衰减至 1×10^{-6} ，整体训练周期设定为 200 个 Epoch。

4.3.2 定量评价与收敛动态剖析

为严密量化所提模型的性能边界与泛化优势，本研究构建了基于控制变量的交叉对比实验矩阵。具体而言，将本文确立的 ResNet-50 与 VGG-16、DenseNet、MobileNet 三种经典骨干网络进行横向对比，旨在评估不同网络拓扑结构对水体多尺度空间特征的表征上限；同时，纵向耦合 Adam 与 SGD 两种优化器，以剥离不同梯度下降策略对非凸损失曲面寻优轨迹的干扰。上述四类主干网络与两类优化器正交组合而成的八种架构方案，均被置于前置定义的五维量化评价体系（PA、F1_Score、mIoU、mPA 及 mPrecision）中进行严格审视。各方案的极值量化评估数据与全局收敛动态轨迹分别详见表 4-2 与图 4-1。

表 4-2 不同主干网络与优化器组合的最高识别精度对比

主干网络与优化器组合	最高 PA(%)	最高 F1_Score(%)
ResNet-50+Adam(本文)	96.7897	94.75
ResNet-50+SGD	94.4729	91.59
VGG-16+Adam	81.2445	69.24
VGG-16+SGD	78.6100	65.83
DenseNet+Adam	82.8770	72.59
DenseNet+SGD	81.8651	71.67
MobileNet+Adam	83.3628	73.45
MobileNet+SGD	81.9363	71.78




图 4-1 采用 Adam 优化器的 U-Net 模型与其他基线模型的对比。

数据清晰地揭示了特征提取架构的代差鸿沟。以 VGG-16 为主干的模型表现垫底（ $F1_Score$ 仅为 69.24%），其根本数理原因在于：VGG 架构缺乏跨层恒等映射机制，在经过连续的池化降采样后，遥感影像中微小水体的空间高频信息发生不可逆耗散，导致解码阶段无法重建精细的水陆边界。MobileNet 虽然参数量极低，但由于感受野特征的通道压缩过度，难以有效捕获水体的复杂光谱异质性。

相比之下，本文所选用的 ResNet-50+Adam 组合在 PA（96.79%）、 $F1_Score$ （94.75%）两项指标上占据了压倒性优势，领先其他非残差基准模型近 10 个百分点。结合训练收敛曲线可以发现，ResNet-50 由于其残差连接（Residual Connection）构建了无损的梯度高速通道；而 Adam 优化器利用一阶矩估计中动量调整和二阶矩估计自适应步长更好地契合本文多目标损失函数（ L_{Total} ）构建的高维非凸损失曲面，避免了 SGD 易陷入局部极小值或遭遇梯度震荡的风险。

为进一步验证定量数据的地学意义，本研究对各模型的输出概率掩膜（Probability Map）做了可视化定性对比。可视化结果如图 4-2 所示：由图中可知，VGG 与 DenseNet 模型在面对光谱特征与水体高度相似的背景干扰时（如建

筑物阴影、云层遮蔽），均出现了大面积的假阳性（误检）斑块；并且在细长河流与破碎池塘的边缘处，这些基准模型的分割结果呈现出严重的“伪影子”以及拓扑断裂问题。

而本文使用的改进 U-Net 模型（ResNet-50+Adam）是所有视觉定性评估中最为接近 Ground Truth。其在边缘细节和极小尺度水体斑块上的出色保真性不仅源于 ResNet-50 深层语义特征的强大判别力，同时更直观地印证了第三章所引入的动态门控机制与 Dice 几何约束损失之物理有效性。动态门控算子能够自适应地感知局部空间复杂度并驱动模型在处于水陆交界上陡峭梯度区域分配更多注意力权重；而通过进化算法实时调优的多目标损失融合策略则从宏观角度保障了对细小水体目标整体的几何连通性。




图 4-2 不同主干网络与优化器组合的水提取结果比较

4.4 消融实验

为深入剖析基于混合进化算法优化的 U-Net 框架中各创新模块的独立贡献与其耦合叠加带来的增益效应，本节设计了详尽的消融实验（Ablation Study）。实验从网络拓扑增强、损失函数多目标重构以及高维超参数寻优策略三个维度，对模型的底层机理进行了严密的控制变量分析。

4.4.1 注意力机制与多目标损失融合的消融分析

本组实验旨在验证 CBAM 与复合损失函数（ $L_{Total} = \lambda \cdot L_{Focal} + \beta \cdot L_{Dice}$ ）在应对水陆类别不平衡及复杂边缘分割时的物理有效性。实验依次向基础 U-Net 模型中注入标准交叉熵损失、Focal loss 以及完整的“Focal+Dice+CBAM”组合，其量化评估结果如表 4-3 所示：

表 4-3 注意力模块与多目标损失融合的消融实验结果

模型变体	PA(%)	F1_Score(%)	mIoU(%)	mPA(%)	mPrecision(%)
U-Net(Base)	96.28	93.9	88.87	93.84	94.66
U-Net+CE Loss	96.67	94.5	89.67	93.85	95.49
U-Net+Focal Loss	96.7	94.5	89.91	93.9	95.46
U-Net+Focal+ Dice+CBAM(本文)	96.93	94.9	90.61	94.62	95.57

由表 4-3 数据可以看出，原生 U-Net 在各个指标上都是最小值。采用 Focal 损失替代标准交叉熵（CE Loss）后，模型的平均交并比（*mIoU*）有了一定的提升，从 89.67%增加到 89.91%。这也从侧面印证第三章中所阐述的数理机制：使用 Focal 损失对简单背景样本实现梯度主导权和难分类边缘水体“硬样本挖掘”的动态聚焦调节因子作用。

当进一步结合 Dice 几何损失以及 CBAM 动态注意力机制后，所有的指标都已经达到最大值。PA 超过了 96.9%，F1_Score 也接近 95%，而代表边界分割精度的 mIoU 更是跨越 90%的高难度水平，达到 90.61%。由此看来光谱/空间自适应特征重标定与宏观拓扑几何约束在水体特征提取中能够产生极强的协同作用。

4.4.2 多源进化算法协同机制的有效性验证

传统的超参数搜索策略极易陷入全局探索与局部开发的固有博弈。为验证本文提出的联合进化策略（Joint Evolutionary Algorithm）的必要性，本组实验横向对比了四种单一进化算法（GA、ACO、PSO、AE）与混合协同策略（Joint）在 U-Net 超参数寻优中的收敛极值。结果如表 4-4、图 4-3 所示。

表 4-4 不同进化算法超参数寻优的性能对比

优化算法	最高 PA(%)	最高 F1_Score(%)
GA	95.58	92.21
ACO	95.79	93.15
PSO	96.11	94.31
AE	96.53	95.57
Joint	97.69	96.32




图 4-3 进化算法与组合算法评估指标的对比

数据表明，在单一算法测试中，AE 凭借其自适应矩阵抽样与动态步长解耦机制，展现出了最优的寻优上限（ $F1_Score$ 达 95.57%）。这一实验结果也从理论上验证了在第三章阶段性权重分配模型中，赋予 AE 算法在收敛后期（精英解压缩阶段）最高主导权重的绝对合理性。

更为重要的是，集成了上述 4 种算法特性的混合进化协同策略（Joint）不仅突破了单一算法的最低像素准确率（PA）达到了 97.69%，F1 分数（ $F1_Score$ ）也达到 96.32%，碾压所有单一进化模型。这一结果表明，混合策略在规避高维损失曲面局部鞍点方面的优异表现，宣告了本研究基于时序感知动态权重分配网络实现全自动化超参数锁定的完备与科学。

采用联合算法优化的模型在所有评估指标上均优于任何单一进化算法优化的模型。此外，评估结果进一步证明，Alpha 进化算法相较于其他三种进化算法具有更优的性能表现。这间接证实了在联合加权策略中为 Alpha 进化算法赋予更高权重是合理的。水体对比结果如图 4-4 所示。




图 4-4 不同进化算法在水体分割结果上的比较

4.5 本章小结

本章围绕混合进化协同优化 U-Net 框架的性能验证，系统性地开展了实证分

析工作。

首先，4.1 节介绍了实验所使用的软硬件计算机，对 Kaggle 和 Sentinel-2 两种源数据集进行几何重构、归一化和样本划分等处理步骤，确保实验的高质量和标准性；然后在 4.2 节详细地给出全局分类效果、几何边界保真度以及类别不平衡处理能力多个参数来定量评价模型效率。在此基础上，为模型性能客观审视提供度量衡。接着，在 4.3 节通过设立典型基准模型并严格配置参数对齐的方式开展详尽的对比实验研究，对主干特征提取网络 and 自适应优化器在非凸损失曲面下的收敛情况进行深入剖析，并且验证了 ResNet-50 架构能够更好地满足遥感密集预测任务；最后在 4.4 节中，通过分组安排不同消融实验，对动态门控注意力机制和多目标损失融合策略以及多源进化算法协同机制等进行控制变量分析，从底层的机理上阐明各创新模块对系统整体性能贡献与增益作用。

本章的实证工作完成了从算法理论到性能验证的逻辑跨越，不仅证明了本文所提框架的稳健性，更为下一章可视化系统的工程化部署提供了核心算法基座。

第五章 可视化应用

5.1 系统整体架构与交互逻辑设计

构建响应式和低延迟的前端架构是实现高维遥感影像实时解析及人机协同交互的工程前提^[41]。本系统选择了基于 Vue 3 组合式 API（Composition API）的单页面应用（SPA）作为串联异构数据流与模型推理调度的最优前端方案^[42]。

在状态调度与视图路由引擎的设计上，系统不需要耗费大量开销对全局进行路由管理。采用基于响应式引用（ref）的状态机（currentView）实现原生级轻量路由。在主控入口（App.vue）中将业务流分割成影像处理流水线（Home View）和模型参数看板（Admin View）两部分独立存放，并通过虚拟 DOM 的<Transition>方式无阻塞切换渲染上下文，避免因为频繁切换视图而造成内存泄漏。此种状态隔离策略能够收敛遥感大图在内存分配上的生命周期，防止内容被浪费的风险。

由于前端渲染速度瓶颈，界面表现层全部向原子级 CSS 引擎（TailwindCSS）下沉。通过添加其他 GPU 硬件加快的合成层样式（如 backdrop-blur-lg 与复合透明度映射 bg-white/5）构建非阻塞的玻璃拟态渲染管线。这大幅降低浏览器在对高分辨率掩膜层（Mask）进行重绘（Repaint）、重排（Reflow）时消耗的算力。

严密的状态调度与轻量级渲染架构的有机耦合，确保了系统在高并发图像 I/O 环境下的帧率稳定性。系统整体的数据流向如图 5-1 所示。这一工程实现直接为后续基于多重事件监听的双视图同步比对框架，以及模型权重的热更新机制，提供了极具鲁棒性的底层支撑。




图 5-1 基于响应式状态流的系统交互架构数据流向图

5.2 核心功能模块的工程实现

前端交互系统作为非结构化遥感影像输入和高维张量输出的缓冲层，是实现

鲁棒性较强的 I/O 管道以及模型工程化闭环最关键和难点。本节将利用可视化界面对影像解析与模型管理两个主要核心模块底层控制逻辑进行分析。

5.2.1 影像拖拽解析与输入校验机制

在系统处理非结构化遥感影像输入时，必须要依据“零信任”原则建立严密的防御性边界，以此隔离非法数据对推理管线的污染。在图像上传器的工程实现中，通过事件驱动的状态机完成这一目标。

在具体实现上，系统利用 HTML5 原生 Drag-and-Drop API 构建了视图层的状态锁定机制。如图 5-2 所示，当外部文件进入挂载区域时，响应式变量 isDragging 触发 DOM 重绘，为用户提供明确的视觉交互锚点。同时，在文件读取阶段（handleFileChange），系统注入了基于正则表达式的轻量级鉴权逻辑，强制提取并校验文件后缀（严格匹配.jpg，.jpeg 格式）。

这种前端鉴权机制的学术意义是：在将物理内存分配和文件切片上传到网络层之前，提前拦截掉不支持的压缩编码（比如含有不可逆噪点的非标格式）或者恶意载荷，通过前置的格式强校验、拖拽状态防抖等措施彻底隔离了非法请求对后端 GPU 算力的占用，从数据源头保证下游增强型 U-Net 模型特征提取张量流的纯净度与推断稳定性。



图 5-2 像拖拽解析与输入校验界面

5.2.2 模型参数看板与动态更新调度

工程化可视化系统的价值就是将黑盒化的深度学习算法转变成能够量化、调度的工程实体。AdminDashboard.vue 模块的作用是 MLOps（机器学习运营）的前端，负责指标映射和权重热重载以及调度等功能。

如图 5-3 所示，该模块在视图层硬绑定了本研究第四章实证研究中获取的核心评价体系（Accuracy96.93%、mIoU90.61%等），将静态学术指标映射为动态前端看板，弥合了理论评估与实际部署之间的语义鸿沟。

此外，为了应对复杂的生产环境，系统单独开放模型权重异步更新部分，并使用 `accept=".pth,.onnx,.pt,.h5"` 属性打通多格式文件。其原因在于支持 PyTorch 原生权重（.pth/.pt）能够快速验证动态计算图，而支持开放神经网络交换格式（.onnx）则有利于系统跳出某些框架依赖、基于 TensorRT 进行底层计算图优化，极大地提高了模型在边缘设备上的部署可达性。模块中包含的异步上传机制和状态反馈（`updateSuccess` 延迟响应）是增强型 U-Net 模型在生产环境下进行不断集成（CI）与持续交付（CD）的基础交互方案。




图 5-3 模型管理看板与动态更新模块

5.2 基于仿射变换的双视图同步渲染机制

遥感影像的定性评估，原图视口和预测掩膜（Mask）视口在空间坐标上都需要保持严格的像素级对齐。由于其中原生 DOM 元素独立滚动、缩放，导致两者之间不仅没有相互关联的空间上下文，更无法满足水陆边界比对的地学特点。因此本系统提出了一种基于仿射变换（Affine Transformation）与状态单例的双视图同步渲染引擎。

如图 5-4 所示，该引擎通过空间坐标的刚性耦合，实现了原图视口与预测掩膜视口在平移、缩放等高频交互事件中的同步响应。




图 5-4 原图与预测掩膜双视图同步渲染界面

在工程实现上，系统将视图的状态向量抽象为二维平移和一维缩放的集合 $T=[x,y,s]^T$ 。系统对影像进行拖拽和缩放时为避免影像脱离容器可视域，设计了 `enforceBounds` 核心约束算法。设定容器尺寸 (W_c, H_c) ，影像物理尺寸 (W_i, H_i) ，最小缩放比 s_{min} 则采用完全覆盖原则计算，如式(5.1)所示：

$$s_{min} = \max\left(\frac{W_c}{W_i}, \frac{H_c}{H_i}\right) \quad (5.1)$$

实际渲染缩放比被严格下限幅为 $s_{final} = \max(s_{min}, s)$ 。在该尺度下，平移坐标的合法解空间被闭包约束为式(5.2)、(5.3)：

$$x_{final} = \min(0, \max(W_c - W_i \cdot s_{final}, x)) \quad (5.2)$$

$$y_{final} = \min(0, \max(H_c - H_i \cdot s_{final}, y)) \quad (5.3)$$

该非线性约束方程在每一次事件分发时执行计算，从算法底层切断了图像平移越界引发的交互异常。进一步地，在处理滚轮缩放事件（`handleWheel`）时，系统抛弃了以图像中心为原点的粗放映射，转而采用以光标实时坐标 (x_c, y_c) 为锚点的视点变换矩阵。图像在标量场中的局部坐标 (x_{img}, y_{img}) 定义为式(5.4)：

$$x_{img} = \frac{x_c - x}{s}, \quad y_{img} = \frac{y_c - y}{s} \quad (5.4)$$

当缩放因子以恒定步长进行指数级演进（本系统设基准缩放系数为1.15）时，即 $s' = s \cdot 1.15^{\pm 1}$ ，新的平移向量更新方程推导如式(5.5)、(5.6)所示：

$$x' = x_c - x_{img} \cdot s' \quad (5.5)$$

$$y' = y_c - y_{img} \cdot s' \quad (5.6)$$

计算结果随后再次经由 `enforceBounds` 算子过滤, 以确保仿射空间的封闭性。

上述空间映射算法将左右两侧异构图像的 DOM 实例挂载至同一个响应式状态机, 保证了时间与空间维度上绝对同步标定。严格代数约束下前端工程设计, 为审评人员验证改进 U-Net 模型在微小水体边界上的保真度提供无偏差量化交互基准。

5.3 异步推演调度与异常处理

高分辨率遥感影像的像素级密集预测任务开销较大, 耗费计算时间长。如果前端发起同步阻塞请求, 浏览器渲染主线程会产生假死 (UI Blocking), 为此本系统设置了基于状态机的异步调度管道, 并在当下阶段给出了前端界面与底层模型解耦原型验证边界。

系统通过响应式变量 (`isProcessing` 与 `errorMsg`) 构建了确定性的有限状态机。在当前的前端原型架构中, 不是将高延迟 HTTP/WebSocket 推理请求直接拉起, 而是采用预计算掩膜 (Pre-computed Masks) 静态路由进行架构连通性校验。在调度流水线中拦截文件输入并分析其基底命名空间后向静态资源池发起非阻塞的资源探测, 依赖 Promise 和原生 Image 对象的生命周期钩子 (`onload/onerror`) 来模拟真实网络 I/O 延迟和握手反馈。这样设计的工程意义之一就是证明了前端状态机在面对不可控推理耗时时的调度鲁棒性、并在逻辑层为后续接入挂载增强型 U-Net 模型的 Python 真实推理服务器预留标准化的异步微服务接口。

对于高频度的遥感图像 I/O 操作, 可能造成内存泄漏 (Memory Leak), 为此在异常捕获和状态重置 (Reset) 环节进行了最底层的内存管理算子设计。当状态机发现资源不足时 (即 404 网络异常并抛出 Error) 或用户主动发起重置指令之后, 系统不仅会更新视图反馈层, 而且还将强制执行 `URL.revokeObjectURL`, 直接在浏览器宿主环境堆内存中释放由 `createObjectURL` 挂载的高分辨率图像 Blob 引用从物理上切断无主对象对显存与内存长期霸占。严密的异常捕获以及确定性的垃圾回收 (GC) 干预保证了大规模切片分析场景下的长效稳定运行。

5.4 本章小结

本章立足于增强型 U-Net 水体识别框架的实际应用, 详细介绍了具有高维张量调度能力和防御性边界的响应式可视化交互原型。针对遥感大图解析过程中常遇到的渲染阻塞、内存溢出等问题, 先确定了基于前端单页面架构 (SPA) 和原子级 CSS 硬件加速的轻量级渲染管线收敛高分辨率掩膜组件生命周期。

在数据链路的输入域, 采用严密的正则鉴权和状态防抖方式, 从物理上彻底切断了非法图像载荷对后端推理管线的污染。在核心交互域引入二维仿射变换和

解空间闭包约束，搭建了底层的双视图同步渲染器，用严格的数学边界代替粗放的 DOM 滚动为多尺度水体边缘定性比对提供一个无偏差的空间对齐基准。

此外，还针对高延迟模型推理的特点设计了基于有限状态机的异步微服务调度管道以及深入介入底层堆内存的垃圾回收与释放过程中，极大提升工程架构在进行大规模切片分析时的物理稳定性。本章所设置的可视化和调度闭环，不仅从工程维度补全算法理论实证链条，而且为后续将深度学习遥感模型应用到异构计算边缘设备的业务部署提供了鲁棒性、延展性良好的框架结构。

第六章 结论与展望

6.1 结论

本文立足于高分辨光学遥感水体提取的自动化演进需求，系统性攻克了传统深度卷积网络高度依赖人工先验干预与水陆类别非对称梯度失活的核心方法论壁垒。

在理论构建与机制重构层面，本文提出了以增强型 U-Net 为基座、混合进化计算为联合驱动的全自动语义分割方法。在模型特征提取域利用 ResNet-50 深度残差网络锚定高维语义，向解码路径植入 CBAM 实现对复杂水文几何特征空间与光谱自适应重标定。在网络寻优域中，针对非凸博弈困境，深度耦合 GA、蚁群优化、粒子群寻优和阿尔法进化四类演化算子，生成时序动态权重分配网络从严密的代数约束上实现超参数空间端到端无人化锁定；同时，多目标复合惩罚机制（Focal 损失和 Dice 损失加权联合）及其系数的进化寻优，从底层收敛逻辑上彻底破解水陆占比失衡带来的泛化障碍。

在实证检验和系统工程落地上，基于双源异构遥感数据集的交叉验证展示了混合进化优化架构极佳鲁棒性。在全部避免启发式人工调参影响下，综合考虑到全局判别效果与局部边缘保真度情况，混合进化优化算法均超越了传统特征提取及单一演化框架，具有强泛化的算法底座。本文还搭建了基于响应式状态流的前端可视化调度系统，通过注入严密的二维仿射变换闭包约束和异步微服务状态机，完成多尺度影像原图和预测掩膜两个视图像素级精确空间对齐、高并发推演全生命周期中宿主内存的工程级稳定。

本研究在数理推演、实证检验与工程验证三重维度上，完成了从宏观水文理论到微观交互架构的系统性收敛，彻底瓦解了遥感图像密集分割对人工配置的路径依赖，为大尺度水资源自动化动态解析确立了高鲁棒的技术方案。

6.2 展望

虽然本文在算法自动化和边缘保真度方面取得了确切的量化增量，但是由于已有算力限制及观测领域限制，这一框架还存在许多必要拓宽的物理与计算上限。对观测数据而言，目前特征映射仅考虑单个光学光谱（Sentinel-2），这导致模型在极端气象如浓云密布或强气溶胶覆盖下的光学反射率变差。引入合成孔径雷达（SAR）等异构数据，实现跨模态张量级联、自监督表征对齐是未来超越全天候动态水网屏障的必由之路。

在算力调度和模型压缩域，大规模的混合进化算子种群繁衍叠加深层残差网络中高维矩阵运算客观上推升了模型训练的碳足迹与推理延迟。因此，下一步工

作需要剥离冗余性庞杂演化冗余，研究轻量化代理模型（**Surrogate Models**）、网络架构搜索（**NAS**）等对非凸空间寻优效用的物理意义，建立低精度的量化推理管线与自适应通道剪枝策略，以期最终可以在保证现有分割边界拓扑高拓扑一致性的前提下实现该自动化架构向无人机载荷等受限边缘计算节点业务化下沉。

参考文献

- [1] Pangestu A M, Puspita A A, Azahro M, et al.Evaluating the effectiveness of NDWI in SWE-GNN-based flood modelling for the Pemali River Basin, Brebes Regency, Indonesia[J].IOP Conference Series: Earth and Environmental Science, 2026, 1586(1):012092-012092.
- [2] He C, Sadeghpour H, Shi Y, et al.Mapping distribution of fractures and minerals in rock samples using Res-VGG-UNet and threshold segmentation methods[J]. Computers and Geotechnics,2024,175106675-106675.
- [3] Maksimovic V, Jaksic B, Milosevic M, et al.Comparative Analysis of Edge Detection Operators Using a Threshold Estimation Approach on Medical Noisy Images with Different Complexities[J].Sensors,2024,25(1):87-87.
- [4] 周飞燕,金林鹏,董军.卷积神经网络研究综述[J].计算机学报,2017,40(06):1229-1251.
- [5] Ronneberger O, Fischer P, Brox T.U-Net: Convolutional Networks for Biomedical Image Segmentation.[J].CoRR,2015,abs/1505.04597
- [6] Dong W, Du B, Xu Y.Shape-intensity-guided U-net for medical image segmentation[J].Neurocomputing,2024,610128534-128534.
- [7] 辜瑞帆,李祥,任维民.基于 ResNet50 改进模型的图像分类研究[J].现代电子技术,2023,46(04):107-112.
- [8] K. M T, Milosz K. Decomposition-Based Interactive Evolutionary Algorithm for Multiple Objective Optimization[J].IEEE Transactions on Evolutionary Computation,2020,24(2):320-334.
- [9] Ye T, Xingyi Z, Chao W, et al.An Evolutionary Algorithm for Large-Scale Sparse Multiobjective Optimization Problems[J].IEEE Transactions on Evolutionary Computation,2020,24(2):380-393.
- [10] 马永杰,云文霞.遗传算法研究进展[J].计算机应用研究,2012,29(04):1201-1206+1210.
- [11] Dorigo M, Gambardella L M .Ant colony system: a cooperative learning approach to the traveling salesman problem[J].IEEE Trans on Ec, 1997, 1(1):53-66.
- [12] Dorigo M, Maniezzo V .Ant system: optimization by a colony of cooperating agents[J].IEEE Trans. on SMC-Part B, 1996, 26(1):29.
- [13] 杨维,李歧强.粒子群优化算法综述[J].中国工程科学,2004,(05):87-94.

- [14] Gao H ,Zhang Q .Alpha evolution: An efficient evolutionary algorithm with evolution path adaptation and matrix generation[J].Engineering Applications of Artificial Intelligence,2024,137(PB):109202-109202.
- [15] McFEETERS, S. K .The use of the Normalized Difference Water Index (NDWI) in the delineation of open water features[J].International Journal of Remote Sensing, 1996, 17(7):1425-1432.
- [16] Xu H .Modification of normalised difference water index (NDWI) to enhance open water features in remotely sensed imagery[J].International Journal of Remote Sensing,2006,27(14):3025-3033.
- [17] Chen J ,Wang Y ,Wang J , et al.The Performance of Landsat-8 and Landsat-9 Data for Water Body Extraction Based on Various Water Indices: A Comparative Analysis[J].Remote Sensing,2024,16(11):
- [18] Salim A ,Rajeev A ,Perumkuni P S , et al.Developing the recommendations for restoration of Ashtamudi Lake, Kerala, India, by data analysis based on a novel water body index using Google Earth Engine[J].Environmental Science and Pollution Research,2025,32(11):1-19.
- [19] 丁世飞,齐丙娟,谭红艳.支持向量机理论与算法研究综述[J].电子科技大学学报,2011,40(01):2-10.
- [20] 吕红燕 , 冯倩 . 随机森林算法研究综述 [J]. 河北省科学院学报,2019,36(03):37-41.
- [21] 方匡南,吴见彬,朱建平,等.随机森林方法研究综述[J].统计与信息论坛,2011,26(03):32-38.
- [22] Kumar M D ,Satyanarayana D ,Prasad G N M .Retraction Note: MRI brain tumor detection using optimal possibilistic fuzzy C-means clustering algorithm and adaptive k-nearest neighbor classifier[J].Journal of Ambient Intelligence and Humanized Computing,2026,(prepublish):1-1.
- [23] rem Gümüü, Altas F ,Beril Türkekul,et al.Water-body Segmentation in Heterogeneous Hydrodynamic and Morphodynamic Structured Coastal Areas by Machine Learning[J].International Journal of Environment and Geoinformatics, 2023.
- [24] Liang-Chieh C ,George P ,Iasonas K , et al.DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs.[J].IEEE transactions on pattern analysis and machine intelligence,2018,40(4):834-848.

- [25] Zhao H , Shi J , Qi X ,et al.Pyramid Scene Parsing Network[J].IEEE Computer Society, 2016.
- [26] Wang G ,Wu M ,Wei X , et al.Water Identification from High-Resolution Remote Sensing Images Based on Multidimensional Densely Connected Convolutional Neural Networks[J].Remote Sensing,2020,12(5):795-795.
- [27] Franz W ,Anette E ,Hans-Gerd M .River water segmentation in surveillance camera images: A comparative study of offline and online augmentation using 32 CNNs[J].International Journal of Applied Earth Observation and Geoinformation,2023,119
- [28] Real E , Moore S , Selle A ,et al.Large-Scale Evolution of Image Classifiers[J].2017.
- [29] Abdullah L ,Tor-Morten G ,Ghulam M , et al.EDCNNs: Federated learning enabled evolutionary deep convolutional neural network for Alzheimer disease detection[J].Applied Soft Computing,2023,147
- [30] 杨莲,石宝峰.基于 Focal Loss 修正交叉熵损失函数的信用风险评价模型及实证[J].中国管理科学,2022,30(05):65-75.
- [31] 胡梦婷,罗晨.基于 MCNN-LSTM 和交叉熵损失函数的轴承故障诊断[J].制造技术与机床,2024,(09):16-22.
- [32] Han B ,He L ,Ke J , et al.Efficient and Accurate Object Detection with Asymmetric Progressive Semi-Decoupled Head and Harmonic Focal Loss.[J].IEEE transactions on image processing : a publication of the IEEE Signal Processing Society,2026,PP
- [33] Shamayleh A S A ,Qatawneh M ,Elsalamony A H .Advanced Retinal Lesion Segmentation via U-Net with Hybrid Focal–Dice Loss and Automated Ground Truth Generation[J].Algorithms,2025,18(12):790-790.
- [34] Kahhoul S Z ,Terki N ,Benaissa I , et al.Mathematical Analysis and Performance Evaluation of CBAM-DenseNet121 for Speech Emotion Recognition Using the CREMA-D Dataset[J].Applied Sciences,2025,15(17):9692-9692.
- [35] 孙海峰,穆正阳,戚琦,等.基于动态门控特征融合的轻量深度补全算法[J].软件学报,2023,34(04):1765-1778.
- [36] Holland J H .Adoption in Natural and Artificial System[J].MIT Press, 1975.
- [37] Kennedy J .Particle Swarn Optimization[C]//Proc of IEEE International Conference on Neural Networks.1995.
- [38] Reddy S B ,Jha R R ,Dasore A , et al.Multi-class classification of brain tumor

- using a ResNet101 backbone integrated with multi-scale deformable attention module and advanced data augmentations.[J].Scientific reports,2026.
- [39] Swapno R M M S ,Nobel N M S ,Islam B M , et al.ViT-SENet-Tom: machine learning-based novel hybrid squeeze–excitation network and vision transformer framework for tomato fruits classification[J].Neural Computing and Applications,2025,37(9):1-18.
- [40] Xin L ,Xiaohua T ,Zhongwen H .An applicable and automatic method for earth surface water mapping based on multispectral images[J].International Journal of Applied Earth Observation and Geoinformation,2021,103.
- [41] 刘思慧.Web 组件在前端架构设计模式中的应用研究[J].信息与电脑(理论版),2024,36(20):63-65.
- [42] 刘泓杰.基于 Vue.js 的视频营销创作平台的研究与设计[D].北京邮电大学,2023.

致 谢

行文至此，本篇基于深度学习与进化计算的遥感水体识别学位论文已完成全部逻辑闭环与实证推演。回溯整个研究周期，本工作的顺利推进与最终定稿，建立在众多师长、同侪及家人的智力输出与情感支撑之上，特在此予以严肃的学术致谢。

感谢我的导师魏培阳。从选定课题，到数理推导，再到实证分析，在整个研究过程中以其严密的逻辑与苛刻的治学标准为本文研究划出了坚实的基准线；特别是网络拓扑重构与多目标损失融合遭遇收敛瓶颈时导师的敏锐洞察和拨冗指点，让本工作没有因启发式调参而低效试错，提升了研究方向的工程可行性和前瞻性。在此谨向魏培阳老师表示诚挚的谢意和最崇高的敬意。

感谢成都信息工程大学空间信息与数字技术专业的全体授课教师。四年的系统化工科训练，不仅夯实了我在空间数据挖掘与算法设计维度的底层基础，更重塑了我对遥感领域与计算机视觉体系的认知坐标，为本论文的跨学科交叉创新提供了完备的理论地基。

感谢我的室友们。四年来，我们从初见时的拘谨客气，到后来的无话不谈，这间小小的宿舍承载了太多温暖的记忆。感谢你们包容我偶尔的作息不规律，感谢你们在我迷茫焦虑时的深夜卧谈，感谢我们悄悄在寝室里煮的一次次火锅。你们的陪伴让异乡求学的日子充满了家的温度。愿我们此去繁花似锦，在各自的道路上闪闪发光。

感谢远在四川泸州的家人。学术探索本质上是一场在未知非凸空间中的漫长寻优。在面对无数个局部极小值的受挫时刻，你们始终如一的理解与无条件的托底，是我能够跨越研究周期的阵痛、最终抵达全局收敛的最底层动量。

学术无涯，诚惶诚恐。本研究仅是对复杂水文遥感解析的一次初步试探，受限于算力与认知，仍存诸多未竟之局。未来，我将秉持这份对科学事实的敬畏与严谨，在后续的科研与工程实践中持续求索。